

图像分类技术演进综述

A Survey on the Evolution of Image Classification Techniques

2026 年 6 月 4 日

摘要

图像分类是计算机视觉领域最基础且最具代表性的任务，其核心技术路线在过去近三十年间经历了从经典设计、卷积神经网络（CNN）、深度残差学习、轻量化网络，到基于自注意力机制的视觉 Transformer（ViT）的多次范式跃迁。本文沿“研究背景—方法演进—成果对比—现存不足—未来展望”的主线，系统梳理了该领域具有里程碑意义的代表性工作。首先明确图像分类的基本定义与评价指标（准确率、Top-5 准确率等），然后重点回顾了 LeNet、AlexNet、VGG、GoogLeNet、ResNet、DenseNet、ResNeXt、MobileNet、EfficientNet、ViT、DeiT、Swin Transformer 等关键模型的核心机制与性能突破。在此基础上，本文深入分析了三次重大范式转移：AlexNet 证明深度学习有效性、ResNet 解决深度网络训练退化问题、ViT 引入纯注意力机制打破 CNN 的归纳偏置。最后，对当前研究在数据依赖、可解释性、计算效率等方面的局限进行了剖析，并对自监督学习、模型轻量化、因果表示等未来方向进行了展望。

关键词：图像分类；卷积神经网络；残差连接；Vision Transformer；自注意力机制；文献综述

引言与研究背景

1.1 图像分类任务定义与评价指标

图像分类是指计算机根据输入图像的视觉内容，自动判断该图像所属的类别标签。这是计算机视觉中最基础的核心任务，也是衡量模型视觉理解能力的标准试金石。

输入：一张固定尺寸的彩色图像，通常表示为 $H \times W \times 3$ 的像素矩阵（高度 $\times$ 宽度 $\times$ RGB 三个颜色通道）。

输出：一个离散的类别标签（如“猫”、“狗”、“飞机”），或者一个概率分布向量，表示图像属于每个预定义类别的可能性。

常用评价指标：

- ① **准确率（Accuracy）** 公式：Accuracy = 正确分类的样本数 / 总样本数（最直观的指标，但在类别不平衡时可能失真。）

② Top-5 准确率 (Top-5 Accuracy)

定义：模型预测的前 5 个最可能的类别中包含真实类别，即视为正确。

主要用于大规模细粒度分类（如 ImageNet 有 1000 类），因为很多图像中物体可能模糊或存在多个疑似类别，允许模型“猜 5 次”更能反映其语义理解能力。

③ 其他指标：精确率 (Precision)、召回率 (Recall)、F1 分数、混淆矩阵等，常用于多标签或类别不平衡场景。

1.2 技术演进的三次进程

从学科发展的宏观视角审视，图像分类领域的研究历程清晰地呈现出三次具有深远意义的范式转移。

第一次范式转移：从“经典设计”向“端到端深度学习”的跨越。

早期方法依赖 SIFT、HOG、LBP 等手工设计的局部特征描述子，结合支持向量机 (SVM) 等分类器。这类方法泛化能力弱，且特征设计依赖人工经验。2012 年 AlexNet 在大规模数据集 ImageNet 上取得突破性胜利，证明了端到端学习的深度卷积网络能够自动学习从像素到语义的分层特征，开启了深度学习主导的新时代。

第二次范式转移：从“浅层卷积网络”向“极深残差网络”的演进。

随着网络层数增加，研究者发现单纯堆叠层数反而导致训练误差上升，即**退化问题**。2015 年 He 等人提出的 ResNet 通过引入**残差连接 (skip connection)** 使网络可稳定训练至上百层，并在 ImageNet 上首次超越人类识别水平。

第三次范式转移：从“卷积归纳偏置”向“纯注意力全局建模”的变革。

2020 年 Dosovitskiy 等人提出的 Vision Transformer (ViT) 将自然语言处理中成功的 Transformer 架构迁移至视觉任务，将图像划分为 Patch 序列，仅依靠自注意力机制学习全局依赖，在大规模预训练数据上刷新了多项分类记录。这一范式从根本上挑战了 CNN “局部连接、平移不变”的设计哲学。

本综述将依次回顾上述三个阶段的关键技术、代表文献、性能优势与固有局限，并通过对比分析揭示技术演进的内在逻辑。

研究方法的历史演进

2.1 经典卷积神经网络：深度学习的破冰者（1998 - 2014）

LeNet（1998）

由 LeCun 等人提出，用于手写数字识别 (MNIST)。结构包括：卷积层 → 池化层 → 卷积层 → 池化层 → 全连接层。奠定了 CNN 的基本组件：卷积提取局部特征、池化降低空间维度、全连接分类。但受限于当时数据和算力，未在大规模通用图像分类上展示潜力。

AlexNet（2012）

Krizhevsky 等人在 ImageNet ILSVRC 挑战赛上将 Top-5 错误率从 26%大幅降至 15.3%，引爆深度学习革命。核心创新：

- ① **ReLU 激活函数**：缓解梯度饱和，加速收敛。（ $f(x)=\max(0, x)$ ）
- ② **Dropout 正则化**：随机失活神经元，防止过拟合。
- ③ **GPU 并行训练**：处理百万级参数。
- ④ **数据增强**：翻转、裁剪、色彩抖动扩充训练集。

意义：证明了“深度”本身是有效的——更深网络配合足够数据与算力，可学习到远超手工特征的代表。

VGG（2014）

Simonyan 与 Zisserman 提出。统一使用 3×3 小卷积核堆叠（如 16 - 19 层），证明了增加深度可提升性能。结构规整，可移植性强，但参数量巨大（约 140M），计算开销高。

方面	AlexNet（8 层）	VGG（16-19 层）
卷积核大小	11×11 , 5×5 , 3×3 混用	一律 3×3
单层参数量(同通道数)	5×5 比 3×3 多 178%	基准（最小）
参数量 / 计算量	相对轻量	较大
最大深度受限于	参数爆炸、过拟合	硬件内存 / 训练时间
能否做到 16 层	不能（参数量爆炸）	能（因为轻量）

小卷积核本身省参数，但 VGG 在深度和通道数上“补回来”的太多了，最终反而远超 AlexNet。

GoogLeNet（2014）

Szegedy 等人提出。核心是 **Inception 模块**：在同一层使用 1×1 、 3×3 、 5×5 等多尺度卷积核，并利用 1×1 卷积降维，在控制计算量的同时增加网络宽度。参数量仅为 VGG 的 1/12，但精度更高。

2.2 深度残差网络与密集连接：突破深度瓶颈（2015 - 2017）

ResNet（2015）

He 等人提出。核心创新：**残差连接**（skip connection）。

$$y = F(x, \{W_i\}) + x$$

其中 x 是输入， F 是需要学习的**残差映射**， x 通过**恒等快捷连接**直接加到输出上。

当最优解接近恒等映射时，只需把 $F(x)$ 推向 0，比直接拟合 x 容易得多。梯度可通过捷径直接回传，缓解梯度消失。实验数据给出了有力佐证：在 152 层的 ResNet 中，残差连接为梯度传播提供了捷径，使深层网络训练更加稳定，有效缓解了梯度消失问题，并支持数百层甚至上千层网络的训练。**这就是 ResNet 为什么能训练更深的网络的原因。**

DenseNet (2017)

Huang 等人提出。密集连接：每一层与之前所有层在通道维度上拼接。优点：极致特征复用，参数效率高，缓解梯度消失。缺点：显存占用大（需存储中间特征图）。

ResNeXt (2017)

Xie 等人提出。采用**分组卷积** + 多分支结构（cardinality），在不增加参数量的前提下提升模型容量。结构介于 VGG 的堆叠与 Inception 的多分支之间，更规整。

2.3 轻量化网络：移动端与实时场景适配（2017 - 2019）

MobileNet (2017)

Howard 等人提出。核心：**深度可分离卷积**（Depthwise Separable Convolution）。将标准卷积分解为：深度卷积（每个通道独立卷积）+ 点卷积（ 1×1 跨通道组合）。计算量降至标准卷积的约 $1/8 - 1/9$ ，适合移动设备。

ShuffleNet (2018)

Zhang 等人提出。结合**分组卷积**与**通道混洗**（channel shuffle），在极低计算量下保持精度。通道混洗允许不同分组之间交换信息，弥补分组卷积的不足。

EfficientNet (2019)

Tan 等人提出。**复合缩放策略**：同时平衡网络深度、宽度和输入分辨率，通过神经架构搜索得到从 B0 到 B7 的一系列模型。在 ImageNet 上达到当时 SOTA 精度，且参数量远小于 ResNet。

2.4 Transformer 时代：自注意力机制重构视觉架构（2020 - 2021）

Vision Transformer (ViT, 2020)

Dosovitskiy 等人首次将标准 Transformer 编码器直接应用于图像分类。工作流程：

- ① **Patch 切块**: 将图像划分为 16×16 的 Patch (图像块)。每个 Patch 被线性投影为一维向量 (类似 NLP 中的词嵌入)。
- ② **加入 CLS Token**: 在序列前加入一个可学习的分类令牌 ([CLS] Token), 用于汇总全局信息。
- ③ **位置编码**: 添加可学习的或固定的位置编码, 保留空间结构。
- ④ **Transformer Encoder**: 由多头自注意力 (Multi-Head Self-Attention) 和前馈网络 (MLP) 堆叠而成。
- ⑤ **分类输出**: 取 [CLS] Token 的最终表示, 输入分类头得到预测。

自注意力机制计算公式:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

其中 Q, K, V 分别为查询、键、值矩阵, d_k 为键的维度。该机制使每个 Patch 可直接关注所有其他 Patch, 实现**全局依赖的一步建模**。

ViT 与 CNN 的本质区别:

维度	CNN	ViT
特征提取	局部卷积, 多层堆叠扩大视野	全局自注意力, 一层内直接建立全图关系
空间信息	隐式通过卷积步长、池化保留	显式添加位置编码
归纳偏置	强 (局部性+平移不变性)	弱 (几乎无)
数据需求	较少数据也能训练	早期 ViT 对大规模预训练数据依赖较强, 但随着 DeiT、MAE 等方法的发展, 其数据效率已得到显著改善。”
计算复杂度	复杂度与图像尺寸、卷积核大小、通道数线性相关。	$O(N^2)$ (N 为 Patch 数量)
长距离依赖	需多层累积, 效率低	第一层即可直接建模, 效率高
代表性模型	ResNet, MobileNet	ViT, Swin Transformer

DeiT (2020)

Touvron 等人提出。通过**知识蒸馏** (使用 CNN 教师指导学生 ViT), 使 ViT 能在 ImageNet-1K (仅 120 万张图) 上有效训练, 降低了数据门槛。

Swin Transformer (2021)

Liu 等人提出。引入**滑动窗口注意力** (Shifted Window Attention)：将自注意力限制在局部窗口内（复杂度降为线性）。跨层移动窗口，使信息在不同窗口间流动，建立跨窗口连接。构建层次化特征金字塔（类似 CNN 的多尺度），适配目标检测、分割等任务。Swin Transformer 在 ImageNet 分类上超越 ViT，且可作为通用视觉骨干网络。

研究方法对比分析

将上述五大类技术范式（经典 CNN、深度残差、轻量化网络、视觉 Transformer）的核心机制、代表文献、优势与局限进行系统对比，如表 1 所示。

表 1：图像分类主要技术范式对比

研究范式	代表文献	核心机制	优势	局限
经典 CNN	LeNet (1998); AlexNet (2012); VGG (2014); GoogLeNet (2014)	卷积+池化+全连接，端到端学习分层特征	自动特征提取；深层结构提升表达能力	梯度消失/爆炸；退化问题；感受野受限
深度残差	ResNet (2015); DenseNet (2017); ResNeXt (2017)	残差/密集连接；分组卷积	训练极深网络；缓解退化；特征复用	参数量较大；DenseNet 显存占用高
轻量化	MobileNet (2017); ShuffleNet (2018); EfficientNet (2019)	深度可分离卷积；通道混洗；复合缩放	计算量小，适合移动端；速度-精度权衡良好	精度略低于大模型；设计复杂
视觉 Transformer	ViT (2020); DeiT (2020); Swin Transformer (2021)	Patch 划分 + 自注意力 + 位置编码	直接建模全局依赖；大数据下性能超越 CNN；可并行	需海量预训练；小数据易过拟合；平方复杂度

从表可以清晰看到：每一次范式跃迁都源于对前一代核心局限的克服——CNN 克服了手工特征的泛化瓶颈；残差网络克服了 CNN 的深度退化；轻量化网络克服了深度模型的计算开销；Transformer 则试图克服 CNN 的局部性先验。然而，新范式也带来了新的挑战。

当前研究的主要局限

尽管以 ViT/Swin 为代表的视觉 Transformer 在分类精度上已超越 CNN，但从系统学术视角审视，该领域仍面临若干深层瓶颈。

4.1 极端依赖海量数据与计算资源

ViT 在大规模预训练（如 JFT-300M）上才能展现优势，若仅使用 ImageNet-1K 训练，其精度不如同等级量的 EfficientNet。这一现象归因于 Transformer 缺乏 CNN 的内置归纳偏置，必须通过海量数据自行学习局部性、平移不变性等结构。然而，获取数亿级标注数据及数百块 GPU/TPU 的算力成本极高，使该研究路径对普通实验室不友好。

4.2 鲁棒性与分布外泛化能力不足

现有模型（包括 CNN 和 ViT）在测试集与训练集同分布时表现优异，但面对轻微分布偏移（如风格迁移、对抗扰动、恶劣天气）或小样本类别时，准确率急剧下降。例如，在 ImageNet-R（渲染风格图像）或 ImageNet-Sketch 上，ViT 的泛化下降幅度有时甚至超过 CNN，表明其学到的仍是数据集中的统计相关性而非真正的物体概念。

4.3 可解释性缺失与因果推理能力弱

深度模型（尤其是 Transformer）的决策过程高度不透明。一个分类为“猫”的图像，究竟是因为猫的耳朵、胡须，还是背景中的沙发？当前特征归因方法（如 Grad-CAM、注意力图）虽能提供热力图，但无法给出因果层次上的解释。这限制了模型在医疗、安防等高风险领域的应用。

4.4 推理效率与边缘部署的矛盾

尽管轻量化网络已大幅降低计算量，但 ViT 等大模型在移动端仍难以实时运行。自注意力的二次复杂度使得高分辨率图像处理极为昂贵。虽然 Swin Transformer 通过局部窗口降低了复杂度，但在高吞吐场景（如视频流分类）中仍需进一步优化。

未来发展方向

基于上述瓶颈与技术演进逻辑，未来图像分类领域的关键突破方向可凝练为以下四点。

5.1 自监督学习与数据高效 Transformer

为降低对海量标注数据的依赖，**自监督学习**（如掩码图像建模、对比学习）正成为重要方向。MAE（Masked Autoencoder，2021）通过随机遮盖大部分图像块并重建缺失像素，使 ViT 能够在无标签数据上高效预训练，后续仅需极少微调即可达到有监督预训练的性能。这一范式有望打破算力壁垒，使中小实验室也能受益于 Transformer 架构。

5.2 模型轻量化与高效注意力

针对 Transformer 的计算冗余，多种高效注意力机制已被提出，如**线性注意力**（将 softmax 替换为核函数，复杂度降至线性）、**稀疏注意力**（限制每个 token 仅关注少数重要 token）。此外，**神经架构搜索**（NAS）正被用于自动发现适用于特定硬件（如边缘设备）的最优 CNN-Transformer 混合架构。

5.3 可解释性诊断与因果表示学习

未来的模型评估将超越准确率单一指标，更加注重错误案例分析与决策归因。借助注意力可视化、探针任务、概念激活向量等技术，研究者可深入剖析模型在特定语义属性上的依赖强度。更进一步，因果表示学习尝试学习与数据生成过程解耦的因子，使模型具有更强的分布外泛化能力。

5.4 卷积与 Transformer 的融合

目前趋势并非非此即彼，而是混合架构——CNN 擅长局部特征提取，Transformer 擅长全局关系建模。ConvNeXt（2022）基于 ResNet 框架吸收 Transformer 设计思想，在保持 CNN 简洁性的同时达到 Swin Transformer 的精度。这类融合路径有望在效率和表达能力之间取得更好平衡。

6. 结语

综上所述，图像分类领域在过去三十年间经历了从经典设计到深度学习、从浅层卷积到极深残差、从局部归纳偏置到全局自注意力机制的深刻技术变革。每一次范式跃迁都是对前一代方法根本性局限的回应：AlexNet 证明了深度网络自动特征学习的有效性；ResNet 通过残差连接解决了深度退化问题，使百层网络成为可能；ViT 则凭借自注意力机制打破了卷积的先验，实现了纯注意力视觉建模。当前视觉 Transformer 所面临的数据饥渴、可解释性弱、计算量大等问题，正催生着自监督学习、高效注意力、因果表示等下一代方法论的萌芽。可以预见，融合 CNN 与 Transformer 优势的混合架构、支持持续学习的轻量模型、以及具备更强鲁棒性的视觉智能，将成为塑造图像分类下一个前沿的关键力量。

参考文献

- [1] LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278-2324. (LeNet)
- [2] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 1097-1105. (AlexNet)
- [3] Simonyan, K., & Zisserman, A. (2015). Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*. (VGG)
- [4] Szegedy, C., et al. (2015). Going deeper with convolutions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1-9. (GoogLeNet)
- [5] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770-778. (ResNet)
- [6] Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. Q. (2017). Densely connected convolutional networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4700-4708. (DenseNet)
- [7] Xie, S., Girshick, R., Dollár, P., Tu, Z., & He, K. (2017). Aggregated residual transformations for deep neural networks. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1492-1500. (ResNeXt)
- [8] Howard, A. G., et al. (2017). MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*. (MobileNet)
- [9] Zhang, X., Zhou, X., Lin, M., & Sun, J. (2018). ShuffleNet: An extremely efficient convolutional neural network for mobile devices. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 6848-6856. (ShuffleNet)
- [10] Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, pp. 6105-6114. (EfficientNet)
- [11] Dosovitskiy, A., et al. (2021). An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*. (ViT)
- [12] Touvron, H., et al. (2021). Training data-efficient image transformers & distillation through attention. In *International Conference on Machine Learning (ICML)*, pp. 10347-10357. (DeiT)
- [13] Liu, Z., et al. (2021). Swin Transformer: Hierarchical vision transformer using shifted windows. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pp. 10012-10022. (Swin Transformer)
- [14] He, K., et al. (2022). Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 16000-16009. (MAE)

本文中 Accuracy、Precision、Recall 等评价指标的定义与公式基于机器学习分类任务的通用学术共识；Top-5 准确率源于 ImageNet 大规模视觉识别挑战赛（ILSVRC）的官方评估体系。

资料查询以及文章润色过程中使用了 chatGpt 和 deepseek 等模型。

图像分类实验报告（路径 B：算法思维）

1. 实验环境

硬件：

GPU: NVIDIA GTX 1060（若不可用则使用 CPU）

CPU: Intel i7 / 8 核

内存: 16GB

软件：

1. Python 3.10
2. PyTorch 2.x
3. torchvision 0.16.x
4. matplotlib 3.x
5. NumPy 2.x

所有模型均在相同环境下训练，以保证对比公平。

2. 数据集与预处理

- 数据集: CIFAR10, 共 60,000 张 32×32 彩色图像, 10 类
 - 训练集: 50,000 张
 - 测试集: 10,000 张
 - 类别: airplane, automobile, bird, cat, deer, dog, frog, horse, ship, truck
 - 预处理:
 - 随机裁剪 (padding=4)、随机水平翻转 (训练集)
 - 转为 Tensor 并归一化 (0.5, 0.5, 0.5)
 - 目的: 增强模型对不同姿态、位置和光照的鲁棒性
-

3. 模型设计与实现

3.1 ResNet18（仓库地址: <https://github.com/kuangliu/pytorch-cifar>）

- 结构: 18 层残差网络, 核心是残差连接 $H(x) = F(x) + x$
- 实验策略:
 - CrossEntropyLoss

- Adam 优化器，学习率：0.001
 - Batch Size 32，训练 20 Epoch
- 代码改动：
 - 增加训练/测试 Loss、Accuracy 记录
 - 保存前 20 个 Epoch 的训练曲线

3.2 VGG19（仓库地址：<https://github.com/kuangliu/pytorch-cifar>）

- 结构：19 层卷积网络，堆叠 3×3 卷积核
- 实验策略：
 - 同 ResNet18
- 代码改动：
 - 增加训练/测试 Loss、Accuracy 记录
 - 保存错误分类图片
 - 绘制 Loss/Accuracy 曲线

3.3 Vision Transformer (ViT)

（仓库地址：<https://github.com/lucidrains/vit-pytorch>）

- 结构：Patch 分割 + Transformer 编码器
- 实验策略：
 - CrossEntropyLoss + Decorr Loss
 - Adam 优化器，学习率 $3e-4$
 - Batch Size 32，训练 20 Epoch
 - 备注：原仓库未实现测试集评估，无 Accuracy

4. 实验设置与基础结果

模型	Batch Size	Epoch	最高 Accuracy	备注
ResNet18	32	20	78%	基准模型
VGG19	32	20	79%	CNN 对比
ViT	32	20	无	补充实验 (Decorr Loss)

- 训练步骤：
 - 初始化模型与优化器

- 前向传播计算 logits + Decorr Loss (ViT)
- 反向传播，更新权重
- 每个 Epoch 完成后在测试集计算 Loss 和 Accuracy
- 保存错误分类图像

5. 错误案例分析

- ResNet18: 真实标签 “cat”，预测 “dog”，原因：姿态相似、图像模糊
- VGG19: 真实标签 “deer”，预测 “horse”，原因：局部特征模糊
- ViT: 真实标签 “frog”，预测 “dog”，原因：小尺寸图像局部特征敏感性不足



- 在 CIFAR10 数据集中，Cat 与 Dog 属于典型易混淆类别。由于图像分辨率仅为 32×32 ，如上图所示动物面部细节和纹理信息有限，因此模型容易将两类样本混淆。
- 改进策略：增加数据增强、训练更多 Epoch、混合模型结构

6. 模型对比分析

指标	ResNet18	VGG19	ViT
参数量	较少	较多	中等
收敛速度	稳定	稍慢	稍快
特征提取能力	局部+全局	局部	全局
测试准确率	78%	79%	无

- ResNet18 收敛稳定且训练快速


- VGG19 参数量大但准确率相近
 - ViT 捕捉全局信息能力强，但计算成本较高
-

7. 训练过程记录与调参逻辑


- 初期观察到 Loss 震荡 → 调整学习率
 - Batch Size 调整为 32 以稳定训练
 - ViT 增加 Decorr Loss 用于正则化
 - 每个模型均记录前 20 个 Epoch 的 Loss 与 Accuracy
-

8. 可视化训练过程

VGG 训练曲线:



ResNet 训练曲线:



曲线显示 Loss 下降、Accuracy 提升，模型收敛稳定。

ViT 模型的最后结果为 loss: 0.009 以及 decorr aux loss: 0.206

9. 经验总结与 Trade-off

- 数据增强和残差连接提高模型泛化能力
- ViT 对全局特征捕捉能力强，但训练成本高
- ResNet18 在小 GPU 环境下表现平衡
- 错误样本分析帮助理解模型弱点和改进方向

10. AI 工具使用声明

本实验在以下环节使用 ChatGPT 辅助：训练代码调试与改动说明以及实验报告润色。